



AI/ML Projekt

Jan Lukeš

Email: honzaxlukes@seznam.cz

Github: <https://github.com/LukesJan>

Střední průmyslová škola elektrotechnická, Praha 2, Ječná 30

Školní projekt v rámci předmětu Programové vybavení

Vypracováno dne: 16.4. 2026

Obsah

1. Úvod.....	3
2. Specifikace požadavků	3
2.1. Popis uživatelů.....	3
2. 3. Nefunkční požadavky	3
3. Návrh datové vrstvy.....	4
3.1 data.....	4
3.1.1 processed.....	4
3.1.2 raw	4
3.2 models.....	5
3.3 notebooks.....	5
4. Architektura aplikace.....	5
4.1. Přehled modulů.....	6
4.1.1. src/crawler.py	6
4.1.2. src/feature_snapshots.py	6
4.1.3. src/feature_updates.py	6
4.1.4. src/model_runtime.py.....	6
4.1.5. src/predict.py	6
4.1.6. src/prediction_export.py.....	6
4.1.7. index.html a script.js.....	6
5. Běh aplikace	7
6. Získávání dat.....	7
7. Konfigurace programu.....	8
8. Instalace a spuštění.....	9
9. Trénink modelů	10
10. Knihovny	12
11. Licence.....	12
12. Závěr	12

1. Úvod

Cílem této práce bylo vytvořit AI/ML model pro predikci fotbalových zápasů pomocí strojového učení. Projekt využívá reálná data z API-Football, ze kterých se vytváří dataset, na tom se pak trénují modely a výsledné predikce se zobrazují ve webovém rozhraní.

Aplikace je zaměřena na pět největších evropských fotbalových lig. Uživatel může zobrazit budoucí zápasy, predikovaného vítěze a odhad Under/Over 2.5 gólů. Součástí je také historická kontrola posledního dokončeného kola.

2. Specifikace požadavků

2.1. Popis uživatelů

- Administrátor/Uživatel: má přístup ke všem funkcím systému.

2. 2. Funkční požadavky

FR1 – Predikce zápasů:

- Systém umožní zobrazit predikci zápasů.


FR2 – Umožní zobrazit historii predikcí minulého kola:

- Systém umožní zobrazit predikci minulého kola a zobrazí i reálné hodnoty.

2. 3. Nefunkční požadavky

NFR1 - Uživatelské rozhraní:

- Webová aplikace




Use case diagram

3. Návrh datové vrstvy

Data jsou rozdělena do tří hlavních částí: raw data, zpracovaná data a uložené modely.

data/raw - CSV soubory se staženými zápasy pro jednotlivé ligy a sezóny

data/processed - finální dataset pro trénink modelů a JSON export pro frontend




3.1 data

Složka data obsahuje všechny datové soubory, se kterými projekt pracuje. Jsou zde uložena původní stažená data ze zápasů i následně zpracované výstupy, které slouží pro trénink modelů a zobrazení výsledků ve frontendu.


3.1.1 processed

Složka data/processed obsahuje zpracovaná data vytvořená z původních raw souborů. Nachází se zde finální dataset pro trénink a vyhodnocení modelů a také soubor upcoming_predictions.json, který slouží jako výstup pro frontend.




3.1.2 raw

Složka data/raw obsahuje původní CSV soubory se staženými zápasy pro jednotlivé ligy a sezóny. Tato data jsou získána z API-Football a tvoří základní vstup pro další zpracování.




3.2 models

Složka models obsahuje uložené natrénované modely strojového učení ve formátu joblib. Dále se zde nachází soubor training_metrics.json, ve kterém jsou uloženy metriky a výsledky posledního tréninku.



3.3 notebooks

Složka notebooks obsahuje Jupyter Notebook použitý pro sestavení datasetu, trénink modelů a jejich vyhodnocení.



4. Architektura aplikace

Aplikace je rozdělena do několika logických částí. První část zajišťuje získání dat z API. Druhá část z raw dat vytváří předzápasové statistiky a finální dataset. Třetí část slouží pro trénink a ukládání modelů. Čtvrtá část provádí samotné predikce a exportuje je do JSON. Poslední část tvoří jednoduchý frontend pro zobrazení výsledků.




Diagram architektury aplikace

4.1. Přehled modulů

Projekt je rozdělen do několika hlavních modulů, z nichž každý plní svou konkrétní úlohu v rámci zpracování dat, predikce a zobrazení výsledků. Toto rozdělení zvyšuje přehlednost projektu a usnadňuje jeho údržbu i další rozšiřování.

4.1.1. `src/crawler.py`

Tento modul patří do vrstvy sběru dat. Jeho úkolem je stahovat zápasy z API-Football a ukládat je do CSV souborů, které slouží jako základní vstup pro další zpracování.

4.1.2. `src/feature_snapshots.py`

Tento modul patří do vrstvy feature engineeringu. Slouží k výpočtu předzápasových statistik týmů, které se následně používají jako vstupní proměnné pro modely strojového učení.

4.1.3. `src/feature_updates.py`

Tento modul také patří do vrstvy feature engineeringu. Zajišťuje průběžnou aktualizaci a doplňování statistik podle odehraných zápasů, aby data odpovídala aktuálnímu stavu týmů.

4.1.4. `src/model_runtime.py`

Tento modul slouží k načítání uložených modelů a jejich použití při samotné predikci výsledků zápasů.

4.1.5. `src/predict.py`

Tento modul patří do spouštěcí vrstvy řídí běh celé predikční části aplikace.

4.1.6. `src/prediction_export.py`

Tento modul patří do exportní vrstvy. Jeho úkolem je sestavit výsledné predikce a uložit je do JSON souboru, který následně využívá frontend.

4.1.7. `index.html` a `script.js`

Tyto soubory patří do frontendové vrstvy. Slouží k načítání výsledků z JSON souboru a jejich zobrazení uživateli v internetovém prohlížeči.

5. Běh aplikace

Při běžném spuštění projektu se nejprve načte konfigurace z `.env` a zkontroluje se dostupnost virtuálního prostředí. Následně se spustí export predikcí přes skript `src.predict`, který v této verzi projektu generuje výstup pro nejbližší dvě kola každé ligy. Výstupem tohoto kroku je soubor `data/processed/upcoming_predictions.json`. Tento soubor následně načte frontend, který se otevře přes lokální HTTP server na portu 8015. Uživatel může ve webovém rozhraní procházet budoucí zápasy, predikovaného vítěze, očekávané skóre a predikci Under/Over 2.5. Součástí výstupu je také historická kontrola posledního dokončeného kola.




Diagram běhu aplikace

6. Získávání dat

Projekt získává vstupní data z API-Football. Crawler stahuje zápasy pro vybrané ligy a sezóny a ukládá je do CSV souborů. Každý soubor odpovídá jedné lize a jedné sezóně.

Z raw dat se následně vytváří finální dataset. Při zpracování se počítají pouze informace známé před zápasem, například forma týmu, body z posledních utkání, vstřelené a inkasované góly, odpočinek mezi zápasy nebo rozdílové statistiky mezi domácím a venkovním týmem.

Tento přístup je důležitý proto, aby model nevyužíval informace, které by v době před zápasem nebyly známy.

7. Konfigurace programu

Projekt používá externí konfigurační soubor .env. Tento soubor slouží především pro uložení API klíče a technických parametrů komunikace s API-Football.

Klíč	Povinnost	Popis
API_FOOTBALL_KEY	ano	API klíč pro přístup k API-Football
API_FOOTBALL_BASE_URL	ano	základní URL adresa API
REQUEST_TIMEOUT_SECONDS	ano	časový limit pro jeden HTTP požadavek
REQUEST_RETRIES	ano	počet opakování požadavku při chybě
REQUEST_SLEEP_SECONDS	ano	prodleva mezi opakovanými pokusy

8. Instalace a spuštění

Projekt můžeme nainstalovat a spustit.

Klonování projektu

- Github: https://github.com/LukesJan/DB_projekt_pv
- Projekt naklonujeme do našeho vývojového prostředí.
- Druhá možnost je, že stáhneme zip pokud nechceme nic programovat a spustíme .bat soubor který se u projektu nachází.

9. Trénink modelů

Po načtení dat byl dataset vytvořen pomocí funkce `build_dataset`, která z historických zápasů generuje předzápasové statistiky týmů. Tento krok představuje hlavní část feature engineeringu.

V rámci základního čištění dat byly odstraněny neplatné záznamy (např. chybějící datum nebo ID zápasu) a upraveny datové typy, zejména převod data na datetime formát.

Dataset byl následně rozdělen na trénovací a testovací množinu v poměru 90:10 pomocí stratifikovaného rozdělení, aby byla zachována distribuce tříd.

Pro predikci výsledku zápasu bylo testováno více modelů (Gradient Boosting, Random Forest a jejich kombinace pomocí `VotingClassifier`). Tyto modely byly vyhodnoceny a byl vybrán nejlepší na základě metrik `log_loss`, `accuracy` a `F1 score`.

Model	Accuracy	F1 macro	Log loss	Poznámka
Voting (GB + RF)	0.513	0.424	1.003	Vybrán - nejlepší celkový výkon
Gradient Boosting	0.518	0.397	1.003	Nejlepší accuracy
Random Forest	0.488	0.471	1.017	Nejlepší F1 macro

Pro predikci počtu gólů byly použity regresní modely, které samostatně predikují góly domácího a hostujícího týmu. Výsledné skóre je následně kombinováno.

Model	MAE (celkem)	RMSE (celkem)	Poznámka
Gradient Boosting	1.314	1.665	Vybrán - nižší MAE
Random Forest	1.316	1.663	Podobný výkon

Pro klasifikaci hranice Under/Over 2.5 gólů byly testovány modely Gradient Boosting a Random Forest, přičemž nejlepší model byl vybrán na základě přesnosti a dalších metrik.

Model	Accuracy	F1	Log loss	Poznámka
Random Forest	0.584	0.653	0.677	Vybrán - stabilní
Gradient Boosting	0.584	0.658	0.677	Podobný výkon

Parametry modelů byly nastaveny ručně na základě experimentování a porovnání výsledků.

Po dokončení tréninku byly modely uloženy pomocí knihovny joblib a využívají se při predikci v runtime části aplikace.




Diagram vývoje modelů

Tabulka finálních metrik

Metrika	Hodnota
Winner accuracy	0.513
Winner F1 macro	0.424
Home goals MAE	0.989
Away goals MAE	0.845
Total goals MAE	1.314
Total goals RMSE	1.665
Goal line accuracy	0.584
Goal line F1	0.653

10. Knihovny

- requests - komunikace s API-Football
- pandas - načítání a zpracování tabulkových dat
- numpy - numerické operace
- scikit-learn - modely strojového učení a vyhodnocení
- python-dotenv - načítání konfigurace ze souboru .env
- joblib - ukládání a načítání natrénovaných modelů
- jupyter - prostředí pro notebook s tréninkem modelů

11. Licence

MIT License

Copyright (c) 2026 Jan Lukeš

Tento projekt je poskytován „tak, jak je“, bez jakýchkoli záruk. Autor nenese odpovědnost za případné škody vzniklé používáním nebo úpravou tohoto projektu.

Projekt lze volně používat, kopírovat, upravovat a sdílet pro vzdělávací a nekomerční účely. Při jakémkoli šíření nebo využití projektu je doporučeno uvést autora.

Jakékoli komerční využití tohoto projektu je možné pouze se souhlasem autora.

12. Závěr

Projekt spojuje práci s externím API, zpracování dat v Pythonu, tvorbu vlastního datasetu, trénink modelů strojového učení a zobrazení výsledků ve webovém rozhraní. Přínosem práce je hlavně to, že ukazuje celý proces od získání dat až po jejich prezentaci uživateli v jedné ucelené aplikaci.